

# Trabajo práctico 2: Reconstrucción de Imágenes Tomográficas: Método Directo

IGNACIO LEMBO FERRARI<sup>1</sup>

<sup>1</sup>ignaciolembo@ib.edu.ar

16 de marzo del 2024.

## 1. TRANSFORMACIONES DE CONTRASTE

Se tiene una imagen *ImagenA.pgm* de  $181 \times 217$  pixels de la cual se obtuvo el histograma de intensidades, como se muestra en la Fig. 1a, y sobre la cual se implementaron diversas transformaciones de contraste. Todas las implementaciones de esta sección se realizaron en python.

En primer lugar, se aplicó una transformación semilinear en los niveles de gris para optimizar el rango dinámico.

Este método consiste en aplicar una transformación de la forma  $T(r) = ar + b$ , con  $r$  la intensidad del pixel,  $a = (I_{max} - I_{min}) / (r_{max} - r_{min})$  y  $b = I_{min} - ar_{min}$ , además

- Si  $ar + b < I_{min} \Rightarrow T(r) = I_{min}$ ,
- Si  $ar + b > I_{max} \Rightarrow T(r) = I_{max}$ .

Se tomó  $I_{min} = 0$  e  $I_{max} = 255$ . Para determinar los valores  $r_{min}$  y  $r_{max}$  de la imagen, se observa, en el histograma de la imagen original, que la mayor cantidad de valores de intensidad se concentran en el rango  $[0, 150]$ . Luego se toma  $r_{min} = 0$  y  $r_{max} = 150$ . De esta manera, se obtiene una transformación semilinear que expande el rango dinámico de la imagen. Cabe destacar que los valores por debajo de  $I_{min}$  y por encima de  $I_{max}$  saturan en dichos valores, lo cual resulta en pérdida de información de la imagen original. En la Fig. 1b se observa la transformación semilinear junto con su correspondiente histograma de intensidades. Se observa que el histograma se corre hacia la derecha y se expande el rango dinámico. Podemos ver, en el histograma de la imagen transformada que se acumulan pixeles con intensidad máxima  $I_{max}$ .

En el histograma de la imagen original se distinguen 4 picos de intensidad, que corresponden 4 regiones de la imagen; De menor a mayor valor de intensidad: Fondo, líquido, materia gris y materia blanca. Se eligieron convenientemente los valores de  $r_{min}$  y  $r_{max}$  para que

la transformación semilinear resalte cada una de estas regiones. El resultado se muestra en la Fig. 2.

Por otro lado, se ecualizó la imagen A como se muestra en la Fig. 3. La ecualización corresponde a una transformación de la forma

$$T(r) = (I_{max} - I_{min}) \sum_{i=0}^r P(i) \quad (1)$$

donde  $P(i)$  es la distribución de probabilidad de que un pixel tenga intensidad  $i$ . En particular, se toma esta distribución normalizando el histograma de intensidades de la imagen original. Se observa que se expande el rango dinámico, mejorando el contraste de la imagen sin acumulación de intensidades como sucedía en la transformación semilinear.

Se pueden realizar otras transformaciones de contraste, como la binarización de la imagen, que consiste en transformar la imagen según

$$T(r) = \begin{cases} 0 & \text{si } r \geq 128 \\ 255 & \text{si } r < 128 \end{cases} \quad (2)$$


o una transformación según una ley de potencias de la forma

$$T(r) = I_{max} \left( \frac{r}{r_{max}} \right)^\gamma \quad (3)$$

donde se tomó  $I_{max} = 255$  y distintos valores de  $\gamma$ .

En la Fig. 4 se muestra la imagen binarizada de la imagen A original. Esta transformación muestra en negro los valores de la imagen por encima de un cierto umbral, en este caso 128, y en blanco el resto. Esto sirve para resaltar estructuras por encima de dicho umbral eliminando el resto de información de la imagen.

En la Fig. 5 se muestra la transformación  $\gamma$  aplicada a la imagenA original. En este caso se ve que valores de  $\gamma < 1$  generan una imagen más brillante y valores de  $\gamma > 1$  más oscura.



**Fig. 5.** Transformación  $\gamma$  aplicada a la imagenA original.

Por último, en las Figs. 6, 7, 8 y 9 se muestran la resta de la imagenA original con la imagenA luego de aplicarle transformaciones de ecualización, binarización y  $\gamma$  con  $\gamma = 0.5, 1.75$  respectivamente.

## 2. INTERPOLACIÓN

Se tomó la imagen C de tamaño  $128 \times 128$  pixels<sup>2</sup> y se interpoló utilizando el método de vecinos más cercanos y bilineal implementados en python para obtener imágenes de  $32 \times 32$ ,  $64 \times 64$ ,  $256 \times 256$  y  $1024 \times 1024$ . La implementación de ambas técnicas se realizó en python. Los resultados se muestran en la Fig. 10. Se observa que la interpolación bilineal es más suave en la transición de la escala de grises que la interpolación por vecinos más cercanos.

## 3. FILTROS EN EL DOMINIO ESPACIAL

Se aplicaron filtros promedios pasabajos a las imágenes A y C con kernels de  $3 \times 3$ ,  $5 \times 5$  y  $7 \times 7$  como se muestra en la Fig. 11 utilizando ImageJ. Estos filtros se definen a partir de kernels de la forma

$$h = \frac{1}{n^2} \begin{bmatrix} 1 & \cdots & 1 \\ \vdots & \ddots & \vdots \\ 1 & \cdots & 1 \end{bmatrix} \quad (4)$$

donde  $n$  es la dimensión de la matriz.

Se observa que a medida que se aumenta la dimensión del kernel, la imagen se vuelve cada vez más borrosa, es decir, el suavizado es mayor.

## 4. FILTROS EN EL DOMINIO DE FRECUENCIAS

Dada una figura con componentes periodicas en su textura como la que se muestra en la Fig. 12a es posible eliminar dichas componentes a partir de un procesamiento en el espacio de frecuencias de dicha imagen. Para esto se calcula la transformada de Fourier rápida (FFT por sus siglas en inglés) de la imagen con ImageJ y luego de reconocer las componentes periodicas, que en el espacio de frecuencias se manifiestan como puntos de alta intensidad, se procede a eliminarlas. Una vez eliminadas estas componentes se antitransforma la imagen (inverse FFT) y se recupera la imagen original con las componentes periodicas eliminadas. En la Fig. 12 se muestra la imagen original (a) y la imagen procesada (b), mientras que en la Fig. 13 se muestra el espacio de frecuencias con la transformada de Fourier de la imagen original (a) y la transformada de Fourier con las componentes periodicas eliminadas (b).

## 5. FILTROS UNSHARP Y HIGHBOOST

Los filtros Unsharp y Highboost son filtros que se utilizan para resaltar los bordes de una imagen, se definen de la siguiente manera: Sea  $f(x, y)$  la imagen original con ruido,  $\tilde{f}(x, y)$  la imagen original luego de aplicarle un filtro pasabajos y  $g(x, y)$  la imagen resultante, entonces los filtros se definen como

- Unsharp:  $g(x, y) = f(x, y) - \tilde{f}(x, y)$
- Highboost:  $g(x, y) = A f(x, y) - \tilde{f}(x, y)$

donde  $A$  es la intensidad del filtro High-boost y vemos que para  $A = 1$  el filtro High-boost es equivalente al filtro Unsharp. Se tomó la imagen A y se le agregó ruido gaussiano con desvío estándar  $\sigma = 5$ . Luego, se aplicaron los filtros Unsharp y Highboost utilizando como filtro pasa bajo promedio con un kernel de  $7 \times 7$ . Los resultados se muestran en la Fig. 14. Se observa que ambos filtros resaltan los bordes de la imagen y amplifican el ruido, lo cual es esperable para este tipo de filtro que esencialmente se comportan como pasa altos. Se puede ver que el filtro Highboost con  $A = 2$  resalta los bordes, conservando mejor la imagen original. En la Fig. 15 se grafica la media cuadrática de la resta entre la imagen con el filtro High-boost y la imagen original sin ruido en función de la intensidad del parámetro  $A$ . Se observa que  $A = 2$  es el valor óptimo para resaltar los bordes de la imagen alejandose lo menos posible (en media) de la imagen original.

## 6. CALIBRACIÓN DE FANTOMAS

Se calcularon las relaciones señal-ruido (SNR) para los cortes 2, 3 y 4 de un fantoma adquiridos con CT HiSpeed. En este caso, se utilizó ImageJ para obtener los histogramas de intensidad de pixel de una región de interés (ROI por sus siglas en inglés) de las imágenes de los fantasmas tomadas como se muestra en la Fig. 16 para el caso de la imagen AAA0002. La SNR se calcula como

$$SNR = \frac{\mu}{\sigma} \quad (5)$$

donde  $\mu$  es la media de la intensidad de la imagen y  $\sigma$  es la desviación estándar en la ROI elegida. En la tabla 1 se muestran los valores de  $\mu$ ,  $\sigma$  y SNR para cada corte. Se observa que el SNR disminuye a medida que disminuye la corriente del tubo de rayos X. Esto es consistente con lo observado en las imágenes de los cortes, donde se observa que a menor corriente, la imágenes se vuelven más ruidosas.

Corte	Corriente (mA)	$\mu$	$\sigma$	SNR
2	180.0	57.074	4.422	12.907
3	100.0	56.722	5.769	9.832
4	60.0	56.728	7.286	7.786

**Tabla 1.** Tabla de corriente, media, desviación estándar y SNR para las imágenes AAA000x siendo x el corte.

Por otro lado, se midieron el ancho total a media altura (FWHM por sus siglas en inglés) del perfil de intensidad del punto del fantoma para los cortes 11, 12, 13 y 14. En la Fig. 17a se muestra el corte 11 y la ROI sobre el cual se obtuvo el perfil de intensidad y en la Fig. 17b se muestra el FWHM para dicho perfil de intensidad. En la tabla 2 se muestran los valores de FWHM para cada corte.

Corte	FWHM
11	5.720
12	2.967
13	6.267
14	4.425

**Tabla 2.** Tabla FWHM para las imágenes AAA00xx siendo x el corte.


Figuras/ImageA\_brute.png

**(a)** ImagenA original junto con su histograma de intensidades.


Figuras/ImageA\_0\_150.png

**(b)** ImagenA transformada junto con su histograma de intensidades.


**Fig. 1.** ImageA original (a) y su transformación semi-lineal con  $r_{min} = 0$  y  $r_{min} = 150$  (b), junto con sus correspondientes histogramas de intensidades. Se observa en la imagen transformada que el histograma se corre hacia la derecha y se expande el rango dinámico.



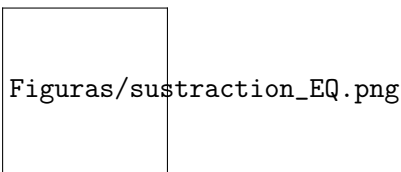
**Fig. 2.** Transformación semilinear aplicada a distintas regiones de la imagen original.




**Fig. 3.** ImagenA ecualizada junto con su histograma de intensidades.




**Fig. 4.** Transformación binaria aplicada a la imagenA original.




**Fig. 6.** Diferencia entre la imagen original y la imagen ecualizada.




**Fig. 7.** Diferencia entre la imagen original y la imagen binarizada.




**Fig. 8.** Diferencia entre la imagen original y la imagen transformada con  $\gamma = 0.5$ .



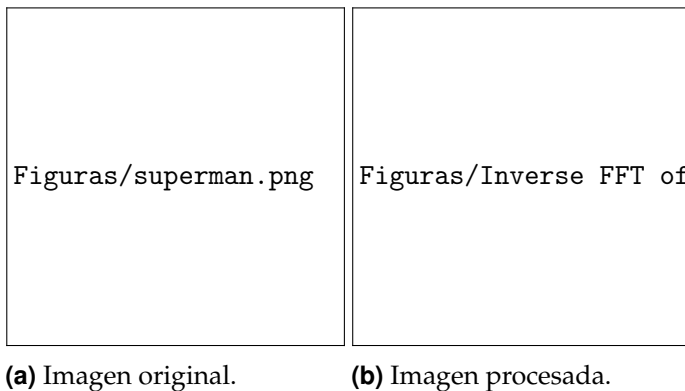
**Fig. 9.** Diferencia entre la imagen original y la imagen transformada con  $\gamma = 1.75$ .



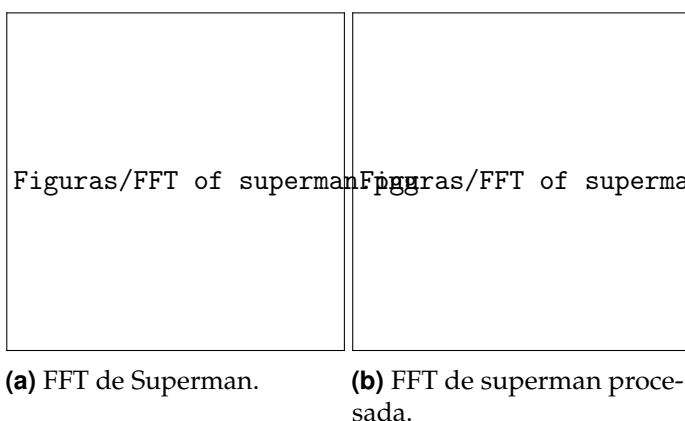
**Fig. 10.** Distintos reescaleos de la imagenC con interpolación por los métodos de vecinos más cercanos (arriba) y bilineal (abajo).



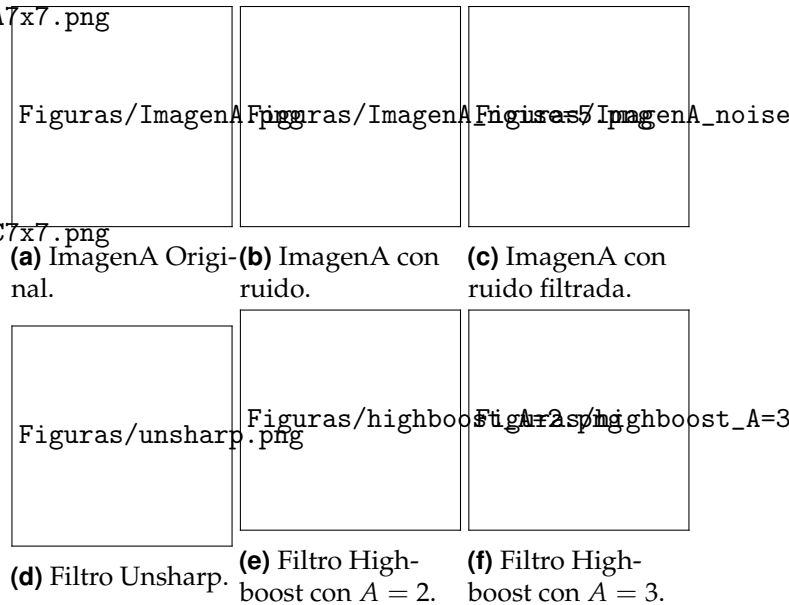
**Fig. 11.** Filtros promedios pasabajos aplicados a la imagenA (arriba) y a la imagenC (abajo) para distintas dimensiones de kernels.



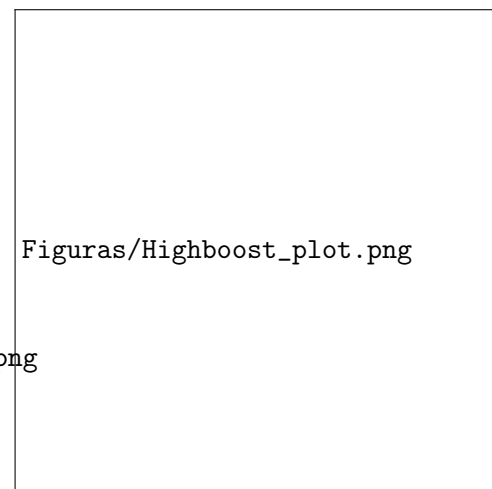
**Fig. 12.** Comparación imagen original de Superman (a) con la imagen procesada (b) en el espacio de frecuencias sin las componentes periódicas en la textura.



**Fig. 13.** Transformada de Fourier rápida de Superman (a). Transformada de Fourier rápida sin las componentes periódicas. En el espacio de frecuencias las componentes periodicas se manifiestan como puntos de alta intensidad.




**Fig. 14.** Filtros Unsharp y Highboost aplicados a la imagenA con ruido gaussiano con desvío estandar  $\sigma = 5$ .

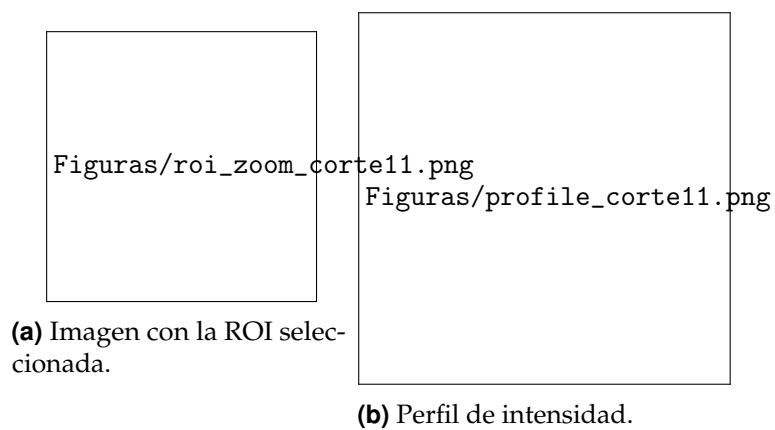


(a) ImagenA original junto con su histograma de intensidades.

**Fig. 15.** Gráfica de la media cuadrática de la diferencia entre la imagen original sin ruido y la imagen filtrada con el filtro High-boost en función del parámetro  $A$ .



**Fig. 16.** Estimación de la SNR para la imagen AAA0002.



**Fig. 17.** Estimación del FWHM para la imagen AAA0011.

## A. APÉNDICE

```

1  import cv2
2  import sys
3  import numpy as np
4  import matplotlib.pyplot as plt
5  import os.path
6
7  def read_pgm_file(file_name):
8
9      data_dir = os.path.dirname(os.path.abspath(__file__))
10
11      # Test if file exists
12      file_path = os.path.join(data_dir, file_name)
13      assert os.path.isfile(file_path), 'file \'{0}\'' does not exist'.format(file_path)
14
15      img = cv2.imread(file_name, flags=cv2.IMREAD_GRAYSCALE)
16
17      if img is not None:
18          print('img.size: ', img.size)
19      else:
20          print('imread({0}) -> None'.format(file_path))
21
22      return img
23
24  def save_img_hist(im, filename):
25
26      vmin = np.amin(im)
27      vmax = np.max(im)
28      print("Intensity Min: {} Max:{}".format(vmin, vmax))
29
30      L = vmax - vmin
31      print("Number of Levels: {}".format(L))
32      fig = plt.figure(figsize=(12,5))
33      ax1 = plt.subplot(1, 2, 1)
34      ax2 = plt.subplot(1, 2, 2)
35
36      # imgplot = plt.imshow(im/np.amax(im))
37      imgplot = ax1.imshow(im, cmap='gray', vmin=vmin, vmax=vmax)
38      fig.colorbar(imgplot, ax=ax1)
39      #ax1.tick_params(direction='in', top=True, right=True, left=True, bottom=True)
40      ax1.tick_params(axis='x', rotation=0, labelsize=15, color='black')
41      ax1.tick_params(axis='y', labelsize=15, color='black')
42      # cv2.imshow(infile, img)
43      # cv2.waitKey(0)
44
45      hist, bin_edges = np.histogram(im.ravel(), bins=L)
46      ax2.bar(bin_edges[:-1], hist, alpha=1, color='b')
47      ax2.set_xlabel(r"Intensidad de pixel", fontsize=15)
48      ax2.set_ylabel(r"N mero de p xeles", fontsize=15)
49      ax2.tick_params(direction='in', top=True, right=True, left=True, bottom=True)
50      ax2.tick_params(axis='x', rotation=0, labelsize=15, color='black')
51      ax2.tick_params(axis='y', labelsize=15, color='black')
52      ax2.set_xlim(-5, 260)
53      #ax2.set_ylim(0, 1000)
54
55      #x1 = rmin # Punto inicial en el eje x
56      #x2 = rmax # Punto final en el eje x
57      #y1 = 0 # Punto inicial en el eje y (puedes ajustar este valor seg n tu necesidad)
58      #y2 = 255 # Punto final en el eje y (puedes ajustar este valor seg n tu necesidad)
59
60      #Agrega la recta al segundo subplot (ax2)
61      #ax2.plot([x1, x2], [y1, y2], color='r', linestyle='-', linewidth=2) # Trama la l nea recta
62
63      fig.savefig(f"{filename}_hist.pdf")
64      fig.savefig(f"{filename}_hist.png", dpi=600)
65      #plt.show()
66
67  def save_img(im, filename):
68
69      vmin = np.amin(im)
70      vmax = np.max(im)

```

```

71     print("Intensity Min: {}    Max:{}".format(vmin,vmax))
72
73     L = vmax - vmin
74     print("Number of Levels: {}".format(L))
75
76     fig, ax = plt.subplots()
77     imgplot = ax.imshow(im,cmap='gray', vmin=vmin, vmax=vmax)
78     ax.axis('off')
79
80     fig.savefig(f"{filename}.pdf", pad_inches = 0, bbox_inches='tight')
81     fig.savefig(f"{filename}.png", dpi=600, pad_inches = 0, bbox_inches='tight')
82     print("Size of image: {}".format(im.shape))
83     #plt.show()
84
85 def SemilinearTrans_pgm_file(im,rmin,rmax):
86     Imin = 0
87     Imax = 255
88     a = (Imax - Imin)/(rmax-rmin)
89     b = Imin - a*rmin
90     imout = a*im + b
91
92     imout = np.where(imout < Imin, Imin, imout)
93     imout = np.where(imout > Imax, Imax, imout)
94     imout = imout.astype(int)
95     return imout
96
97 def Equalize_pgm_file(im):
98     imout = im
99     vmin = np.amin(im)
100    vmax = np.max(im)
101    L = vmax - vmin
102    hist, bin_edges = np.histogram(im.ravel(),bins=L)
103    hist_norm = hist / np.sum(hist) #Normaliza el histograma
104
105    suma = 0
106    for i in range(0,im.shape[0]):
107        for j in range(0,im.shape[1]):
108            suma = 0
109            for e in range(0,im[i,j]):
110                suma += hist_norm[e]
111            imout[i,j] = 255*suma
112
113    imout = imout.astype(int)
114    return imout
115
116 def Trans_binary(im):
117     imout=np.where(im<128,255,0)
118     imout = imout.astype(int)
119     return imout
120
121 def Trans_exponential(im,gamma):
122     imout=im
123     imout=255*(imout/im.max())**gamma
124     imout=imout.astype(int)
125     return imout
126
127 def sustraction(im1,im2):
128     imout = im1 - im2
129     return imout
130
131 def interpolate_nn(im,f):
132     Nx, Ny = im.shape[0],im.shape[1]
133     Mx=int(f*Nx)
134     My=int(f*Ny)
135     imout=np.ndarray((Mx,My), dtype=int)
136
137     for x in range(Mx):
138         for y in range(My):
139             imout[x][y]=im[round(x*Nx/Mx)%Nx][round(y*Ny/My)%Ny]
140
141     return imout
142

```



```

143 def interpolate_bilinear(im, output_width, output_height):
144
145     # Calculate scaling ratios
146     old_height, old_width = im.shape[:2]
147     x_ratio = old_width / output_width
148     y_ratio = old_height / output_height
149
150     # Create new image array
151     new_img = np.zeros((output_height, output_width), dtype=np.uint8)
152
153     # Perform bilinear interpolation
154     for y in range(output_height):
155         for x in range(output_width):
156             x_original = x * x_ratio
157             y_original = y * y_ratio
158             x0 = int(x_original)
159             y0 = int(y_original)
160             x1 = min(x0 + 1, old_width - 1)
161             y1 = min(y0 + 1, old_height - 1)
162
163             Q11 = im[y0, x0]
164             Q21 = im[y1, x0]
165             Q12 = im[y0, x1]
166             Q22 = im[y1, x1]
167
168             x_weight = x_original - x0
169             y_weight = y_original - y0
170
171             R1 = Q11 * (1 - x_weight) + Q12 * x_weight
172             R2 = Q21 * (1 - x_weight) + Q22 * x_weight
173
174             P = R1 * (1 - y_weight) + R2 * y_weight
175
176             new_img[y, x] = P
177
178     return new_img
179
180 def high_boost(im, im_filtered, A):
181     imout = A*im - im_filtered
182     return imout
183
184 def unsharp(im, im_filtered):
185     imout = im - im_filtered
186     return imout
187
188 if __name__ == "__main__":
189
190     if (len(sys.argv) < 3):
191         print("Usage: python read-write-pgm.py [infile.pgm] [outfile.pgm]")
192         exit(1)
193
194     infile1 = sys.argv[1]
195     outfile1 = sys.argv[2]
196     #infile2 = sys.argv[3]
197     #outfile2 = sys.argv[4]
198
199     img1 = read_pgm_file(infile1)
200     #img2 = read_pgm_file(infile2)
201     im1 = np.array(img1)
202     #im2 = np.array(img2)
203
204     #Brute image
205     print("\n Brute image:")
206     print("Size of image 1: {}".format(im1.shape))
207     #print("Size of image 2: {}".format(im2.shape))
208     save_img_hist(im1, "ImageA_brute", 0, 150)
209
210     #Semilinear transformation for different rmin values
211     print("\n Semilinear transformation")
212     img = read_pgm_file(infile1)
213     im = np.array(img)
214     rmax = 150 # 25, 62 , 113 , 150

```

```

215 rmin = 113 # 0, 25 , 62 , 113
216 imout = SemilinearTrans_pgm_file(im,rmin,rmax)
217 print("Size of image: {}".format(imout.shape))
218 save_img_hist(imout,"ImageA_"+str(rmin)+"_"+str(rmax))
219 save_img(imout,"ImageA_"+str(rmin)+"_"+str(rmax))
220
221 #Equalize image
222 print("\n Equalize image")
223 imout = Equalize_pgm_file(im1)
224 save_img_hist(imout,"ImageA_EQ")
225 save_img(imout,"ImageA_EQ")
226 #cv2.imwrite(outfile1,imout,[cv2.IMWRITE_PXM_BINARY,0])
227
228 #Transformaci n binaria
229 print("\n Transformaci n binaria")
230 imout = Trans_binary(im1)
231 save_img(imout,f"ImageA_binary")
232 #cv2.imwrite(outfile1,imout,[cv2.IMWRITE_PXM_BINARY,0])
233
234 #Transformaci n exponencial
235 print("\n Transformaci n exponencial")
236 gamma = 0.5
237 imout = Trans_exponential(im1,gamma)
238 save_img(imout,f"ImageA_exp_gamma={gamma}")
239 #cv2.imwrite(outfile1,imout,[cv2.IMWRITE_PXM_BINARY,0])
240
241 #Interpolate nn
242 f = 0.25
243 print("\n Interpolate NN")
244 imout = interpolate_nn(im1,f)
245 save_img(imout,f"Interpolate_nn_f={f}")
246
247 #Interpolate bilinear
248 #f = 0.25
249 print("\n Interpolate bilinear")
250 imout = interpolate_bilinear(im1, int(f* im1.shape[0]), int(f* im1.shape[1]))
251 save_img(imout,f"Interpolate_bilinear_f={f}")
252 cv2.imwrite(outfile1,imout,[cv2.IMWRITE_PXM_BINARY,0])
253
254 #Sustraction
255 print("\n Sustraction")
256 imout = sustraction(im1,im2)
257 save_img(imout,f"sustraction_exp_gamma=0.5")
258 cv2.imwrite(outfile1,imout,[cv2.IMWRITE_PXM_BINARY,0])
259
260 #Unsharp filter
261 print("\n Unsharp filter")
262 imout1 = unsharp(im1,im2)
263 imout1 = np.array(imout1)
264 print("Size of image 1: {}".format(imout1.shape))
265 save_img(imout1,"unsharp")
266
267 #HighBoost filter
268 print("\n HighBoost filter ")
269 A=3
270 imout2 = high_boost(im1,im2,A)
271 imout2 = np.array(imout2)
272 print("Size of image 2: {}".format(imout2.shape))
273 save_img(imout2,f"highboost_A={A}")
274
275 #High Boost filter plot
276 print("\n High Boost filterplot")
277 A = np.arange(0.5, 10.5, 0.5)
278 S = ([])
279
280 for a in A:
281     imout2 = high_boost(im1,im2,a)
282     im_sust = sustraction(imout2,im1)
283     matriz_cuadrada = np.square(im_sust)
284     suma_total = np.sum(matriz_cuadrada)
285     media = np.sqrt(suma_total / im_sust.size)
286     S = np.append(S, media)

```

```
287     #imout2 = np.array(imout2)
288     #print("Size of image 1: {}".format(imout2.shape))
289     #imout2 = Equalize_pgm_file(imout2)
290     #save_img(imout2,f"highboost_A={A}")
291     #cv2.imwrite(outfile2,imout2,[cv2.IMWRITE_PXM_BINARY,0])
292
293 fig, ax = plt.subplots(figsize=(8, 6))
294 ax.plot(A, S, linewidth=2)
295 ax.set_xlabel(f"Intensidad del filtro HighBoost $A$", fontsize=15)
296 ax.set_ylabel(f"Suma cuadratica media", fontsize=15)
297 ax.tick_params(direction='in', top=True, right=True, left=True, bottom=True)
298 ax.tick_params(axis='x', rotation=0, labelsiz=15, color='black')
299 ax.tick_params(axis='y', labelsiz=15, color='black')
300 #ax.set_xlim(-5, 260)
301 #ax2.set_ylim(0, 1000)
302 fig.savefig(f"Highboost_plot.pdf", pad_inches = 0, bbox_inches='tight')
303 fig.savefig(f"Highboost_plot.png", dpi=600, pad_inches = 0, bbox_inches='tight')
```